

California Housing – modellering som beslutsunderlag Rapport

Mål & valt spår

Målet med uppgiften var att bygga en maskininlärningsmodell som kan förutsäga bostadsvärden i olika områden i kalifornien baserat på geografiska och socioekonomiska variabler. Syftet är att skapa ett beslutsunderlag som kan hjälpa företag eller andra kunder att göra mer datadrivna investeringar och analyser. Jag valde regressionsspåret (spår A) eftersom uppgiften handlade om att förutsäga ett numeriskt värde (`median_house_value`).

Kort data-insikt (EDA)

Datasetet var relativt blandat, det fanns kategoriska och numeriska variabler. De saknade värdena fanns i en kolumn (`total_bedrooms`) och hanterades med `SimpleImputer(strategy="median")`. Targetvariabeln var högerskev med vissa mycket höga bostadsvärden. Ett tydligt positivt samband observerades mellan `median_income` och `median_house_value`.

Metod (ML-flöde)

Beskriv kort varför vi har ett testset och hur du använder det. Hur du delade data (train/test) och hur du utvärderade

Datasetet delades upp med `train_test_split` där 80% användes för träning och 20% för testning. Testsetet användes för att utvärdera modellens generaliseringsförmåga på ny data.

Preprocessing genomfördes med **pipelines** och **ColumnTransformer**. Numeriska variabler hanterades med **SimpleImputer** och **StandardScaler**, medan den kategoriska variabeln hanterades med **SimpleImputer** och **OneHotEncoder**.

Vilka modeller du testade och varför (kort)

Modellerna som testades var: **DummyRegressor**, **Linear Regression**, **Random Forest Regressor** och **Gradient Boosting Regressor**. **DummyRegressor** användes som baseline för att kunna jämföra de riktiga ML modellerna mot en väldigt enkel modell. Modeller med olika egenskaper testades för att jämföra prestanda på datasetet. För utvärdering användes främst RMSE eftersom stora fel i bostadsprognoser är särskilt problematiska. RMSE straffar större fel hårdare än [T.ex.](#) MAE och är därför relevant i detta case. MAE och R^2 användes som kompletterande mått. Gradient Boosting valdes för optimering eftersom modellen presterade starkt i den initiala modell jämförelsen och bedömdes ha förbättringspotential. Vid tuning optimerades parametrarna: **n_estimators**, **learning_rate** och **max_depth**. Optimeringen genomfördes med `GridSearchCV` och `5_fold cross_validation`.

Resultat

Jämförelse av modeller (kort)

Modell jämförelsen visade att ensemblemodellerna presterade bäst på datasetet. Random Forest gav lägst RMSE och högst R^2 av samtliga modeller.

Modell	RMSE	MAE	R2
Random forest	48721.968199	31435.282816	0.818848
Gradient Boosting	55903.124191	38278.148174	0.761513
Linear Regression	70059.193339	50670.489236	0.625438
Dummy	114485.63543	90606.854900	-0.000219

Resultat efter tuning av vald modell

Tuned Gradient Boosting förbättrades med ca 3700 RMSE jämfört med ursprungsmodellen.

Modell	RMSE	MAE	R2
Tuned Gradient Boosting	52142.797906	35477.862046	0.792517
Gradient Boosting	55903.124191	38278.148174	0.761513

Slutlig test-prestanda

Trots att Gradient Boosting förbättrades efter tuning gav Random Forest fortfarande bäst slutlig prestanda på testdata.

Rekommendation

Random Forest Regressor rekommenderas eftersom den gav lägst RMSE och högst R2 på testdata.

Risker & begränsningar

Datasetet innehåller endast data från Kalifornien vilket kan begränsa modellens generaliseringsförmåga. Variablerna är aggregerade på områdesnivå och bostadsmarknaden kan förändras över tid. För att minska risken för dataläckage gjordes preprocessing i pipelines efter train/test split.

Oövervakad inlärning

Oövervakad inlärning används för att hitta mönster i data utan targetvariabel. I detta case kan det användas för att identifiera liknande områden eller upptäcka strukturer i datan. PCA används för dimensionsreducering medan klustring används för att hitta grupper av liknande observationer. Metoderna kan vara svåra att tolka och är ofta känsliga för skalning.

Självreflektion

Jag tycker att jag lyckats bra med att skapa ett komplett och reproducerbart ML-flöde med preprocessing, pipelines, modelljämförelse och optimering.

Det svåraste var att få pipelines och GridSearchCV att fungera korrekt tillsammans, speciellt när parametrar skulle testas.

Jag tycker att min inlämning motsvara ett **G** eftersom att samtliga krav för G-nivån uppfylls, inklusive EDA, preprocessing, modelljämförelse, hyperparameter-tuning och reproducerbar notebook.

